A/B-тест новой формы оплаты ЖКХ

Исходный код

Код обработки данных, расчёта метрик и статистических тестов: GitHub ↗

Гипотеза: автозаполнение реквизитов помогает клиенту пройти форму оплаты и чаще завершать платёж.

Основная метрика - доля успешных попыток среди открытий формы: p_A для контроля и p_B для новой формы.

Данные и качество

В исходном файле 1 504 пользователя и 2 661 попытка. Исключены две попытки: без `user_id` и с противоречивой A/B-группой. Некорректные возрасты помечены как пропуски, но соответствующие платежи сохранены.

После очистки: **2 659 попыток от 1 501 активного пользователя** (A - 751; B - 750). Это не все участники исходной пользовательской таблицы, а клиенты с завершённой попыткой оплаты.

Главный результат:

Конверсия p_A	Конверсия p_B	Эффект Δ
49,77%	**64,40%**	**+14,63 п.п.**

На каждые 100 открытий формы новая версия связана примерно с **15 дополнительными успешными оплатами**. Клиент реже остаётся с незавершённым платежом. Сервис потенциально получает больше завершённых операций из того же входящего потока.

Изменение воронки

Метрика	A	B	Δ
CR 1-2: ввели реквизиты	81,12%	88,38%	+7,26 п.п.
CR 1-3: подтвердили платёж	57,95%	71,06%	+13,11 п.п.
CR 1-4: успешная оплата	49,77%	64,40%	+14,63 п.п.
CR клиентов с ≥1 успехом	65,65%	80,40%	+14,75 п.п.

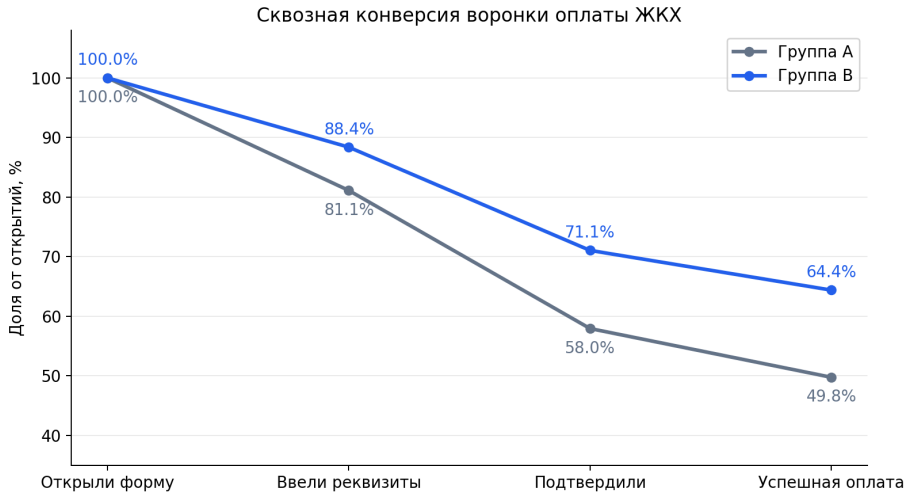


Рис. 1. Кумулятивная конверсия: доля открытий, дошедших до каждого этапа.

Продуктовая интерпретация. CR 1-2 повысился: меньше клиентов теряются при вводе реквизитов - именно здесь ожидался эффект автозаполнения. Разница увеличивается к подтверждению, поэтому улучшение не ограничивается одним полем ввода. При этом медианное время заполнения среди завершивших шаг - **1 минута в обеих группах**: ускорение процесса для таких клиентов не доказано.

Статистическая проверка и решение

Проверка результата

Проверяется гипотеза $H_0 : p_B - p_A = 0$ против альтернативы $H_1 : p_B - p_A \neq 0$, где p_A и p_B — конверсии в успешную оплату по попыткам.

Рандомизация проводилась по пользователям, при этом один пользователь мог совершить несколько попыток оплаты. Следовательно, наблюдения внутри одного пользователя зависимы. Стандартный z-тест по попыткам не учитывает эту зависимость и может занижать стандартную ошибку.

Использован **кластерный bootstrap** (12 000 повторов): пользователи случайно выбираются с возвращением внутри каждой группы вместе со всеми их попытками. Это сохраняет зависимость наблюдений и позволяет оценить 95% доверительный интервал разницы конверсий.

Дополнительно выполнен двусторонний перестановочный тест на уровне пользователей для проверки нулевой гипотезы. Уровень значимости - 5%.

95% интервал для Δ

[+11,04; +18,32]

Перестановочный тест

p < 0,00005

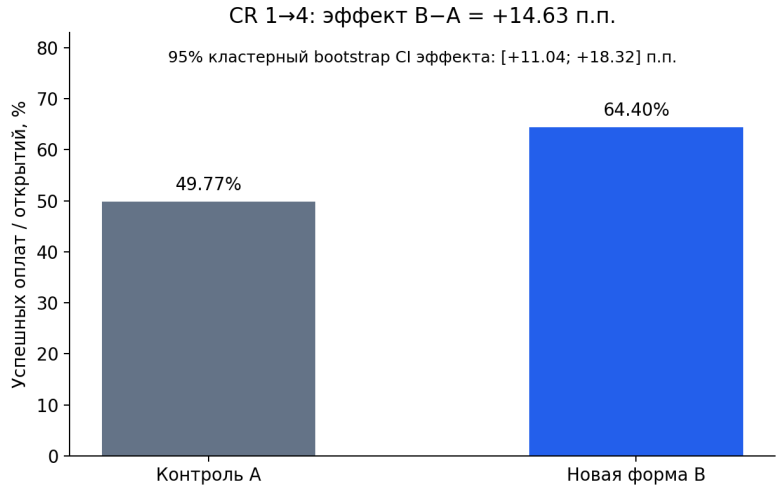


Рис. 2. Конверсия по попыткам в A и B и неопределённость оценки эффекта.

Совместимые с данными значения прироста составляют примерно **11–18 дополнительных успешных оплат на 100 открытий**. Даже нижняя граница указывает на заметное продуктовое улучшение. Малое p-value не показывает размер эффекта - его характеризуют Δ и доверительный интервал.

Проверка на уровне клиентов

Доля активных пользователей, совершивших хотя бы одну успешную оплату: **65,65% в A** против **80,40% в B** (+14,75 п.п.; двусторонний z-тест, $p < 0.001$). Это важно для бизнеса, потому что эффект наблюдается не только в количестве попыток, но и в доле клиентов, которым удалось оплатить ЖКХ хотя бы раз. В отличие от конверсии по попыткам, каждый клиент здесь учитывается один раз. Метрика охватывает только клиентов с успешным открытием формы.

Итог

Рекомендация - поэтапно запускать новую форму.

Основная конверсия устойчиво выше, а улучшение возникает на этапе заполнения, как и ожидалось. Новая форма сокращает потери пользователей в процессе оплаты и повышает долю успешно завершённых операций.

Дополнительно рекомендуется контролировать при запуске долю технических отказов и возвратов, частоту повторных попыток, суммы успешных платежей, число ошибок в реквизитах и стабильность событий воронки. Высокая конверсия сама по себе не гарантирует отсутствие финансовых или операционных проблем.

Ограничения. Эффект по попыткам зависит от активности пользователей; интервалы учитывают группировку попыток по клиентам.